Nama : Debora Z Siagian
Tugas : Week 3
Dataset : GSE10072 (Lung Adenocarcinoma dan Normal)

Gene expression signature of cigarette smoking and its role in lung adenocarcinoma development and survival

Pendahuluan

Kanker paru-paru merupakan salah satu penyebab utama kematian terkait keganasan di seluruh dunia, dengan angka kejadian dan mortalitas yang terus meningkat setiap tahunnya. Di antara berbagai subtipe histologis, adenokarsinoma paru (lung adenocarcinoma/LUAD) tercatat sebagai subtipe yang paling sering didiagnosis, mencakup hampir 40% dari seluruh kasus kanker paru-paru. Kompleksitas patogenesis LUAD, yang melibatkan akumulasi perubahan genetik dan epigenetik, memerlukan pemahaman molekuler yang mendalam untuk mengembangkan strategi diagnosis dini, prognostik, dan terapi yang lebih efektif (Dai *et al*., 2019). Identifikasi perubahan ekspresi gen antara jaringan tumor dan jaringan normal menjadi langkah fundamental dalam mengungkap mekanisme biologis yang mendasari inisiasi dan progresivitas penyakit ini. Kemajuan teknologi microarray dan sekuensing transkriptom telah memungkinkan dilakukannya profil ekspresi gen secara simultan dalam skala genom. Data mentah yang dihasilkan dari eksperimen tersebut umumnya tersedia secara bebas melalui repositori publik seperti Gene Expression Omnibus (GEO). Data GSE10072 adalah salah satu dataset yang berkontribusi signifikan dalam studi LUAD. Dataset ini dipublikasikan oleh Landi dkk. (2008) dan berisi profil ekspresi gen dari 107 sampel, yang terdiri atas 58 jaringan tumor dan 49 jaringan normal paru-paru. Tujuan utama dari studi awal tersebut adalah untuk memahami tanda tangan molekuler yang terkait dengan kebiasaan merokok dalam perkembangan dan kelangsungan hidup pasien LUAD (Landi *et al*., 2008). Ketersediaan data ini membuka peluang besar bagi para peneliti untuk melakukan analisis ulang dengan pendekatan dan pertanyaan penelitian yang berbeda.

Dalam era biologi komputasional, analisis data transkriptomik publik seperti GSE10072 memerlukan perangkat lunak yang andal dan reprodusibel. Bahasa pemrograman R, dengan ekosistem paket Bioconductor-nya yang kaya, telah menjadi standar emas untuk analisis data genomik. Paket limma (Linear Models for Microarray Data) menyediakan metode statistik yang robust untuk mengidentifikasi gen yang diekspresikan secara berbeda (Differentially Expressed Genes/DEG) antara dua kondisi yang berbeda, misalnya antara grup penyakit (kanker) dan grup kontrol (normal). Dengan memanfaatkan limma di lingkungan R, peneliti dapat melakukan serangkaian analisis mulai dari pra-pemrosesan data, normalisasi, pemodelan statistik, hingga visualisasi hasil secara komprehensif (Xiao *et al*., 2017). Oleh karena itu, studi ini bertujuan untuk melakukan analisis ulang terhadap dataset GSE10072 dengan menggunakan bahasa pemrograman R untuk mengidentifikasi DEG antara jaringan LUAD dan jaringan paru-paru normal. Dengan membandingkan langsung kedua grup tersebut, penelitian ini diharapkan dapat memvalidasi temuan gen-gen kunci yang sebelumnya telah dilaporkan, serta berpotensi menemukan kandidat

gen baru yang mungkin terlibat dalam patogenesis LUAD. Hasil dari analisis ini dapat menjadi landasan untuk studi fungsional lebih lanjut serta pengembangan biomarker diagnostik atau target terapi yang potensial

Metode

Berdasarkan Dataset yang digunakan, penulis membuat desain secara keseluruhan yang terdiri atas 180 sampel jaringan adenokarsinoma dan non-tumor dipilih untuk analisis, termasuk sampel duplikat atau rangkap tiga dari 14 subjek untuk kontrol kualitas. Dari 180 sampel asli, 148 menyediakan kuantitas RNA berkualitas tinggi yang cukup untuk analisis microarray; 13 sampel tambahan dikeluarkan karena pengujian yang bermasalah. Normalisasi dilakukan pada 135 microarray yang tersisa. Setelah normalisasi, 13 sampel dikeluarkan karena persentase sel tumor yang rendah dalam jaringan tumor. Laporan ini didasarkan pada 122 sampel, di mana 15 duplikat dirata-ratakan, menghasilkan 107 nilai ekspresi akhir dari 58 jaringan tumor dan 49 jaringan non-tumor dari 20 orang yang tidak pernah merokok, 26 mantan perokok, dan 28 perokok aktif.

Penggunaan bahasa pemrograman R dilakukan dengan mengacu pada modul, yang diawali dengan penentuan Dataset yang akan digunakan. langkah selanjutnya akan dilampirkan pada gambar di bawah ini:

Hasil dan Interpretasi

1. Plot Densitas

Gambar tersebut menunjukkan plot densitas (*density plot*) dari nilai ekspresi gen yang telah ditransformasi ke dalam skala $\log_2$. Distribusi data dari kedua kelompok, yaitu *Adenocarcinoma of the Lung* (merah) dan Normal *Lung Tissue* (biru), menunjukkan profil yang hampir identik dan saling tumpang tindih secara sempurna. Hal ini mengindikasikan bahwa data telah melalui proses normalisasi yang efektif, seperti *Robust Multi-array Average* (RMA) atau *Quantile Normalization*, yang bertujuan untuk menghilangkan variasi teknis antar sampel sehingga perbandingan biologis dapat dilakukan secara valid (Bolstad *et al*., 2003). Secara statistik, kurva menunjukkan distribusi unimodal dengan puncak densitas (mode) berada pada kisaran nilai $\log_2$ antara 7 hingga 8. Rentang ekspresi yang luas, mulai dari nilai 4 hingga 15, mencerminkan keragaman tingkat transkripsi gen dalam jaringan paru-paru, mulai dari gen dengan ekspresi rendah hingga gen *housekeeping* dengan ekspresi sangat tinggi. Kesamaan bentuk kurva ini sangat krusial dalam analisis mikroray untuk memastikan bahwa perbedaan ekspresi yang nantinya ditemukan (DEGs) benar-benar berasal dari kondisi biologis, bukan karena perbedaan teknis dalam pemuatan sampel atau intensitas sinyal (Landi *et al*., 2008).

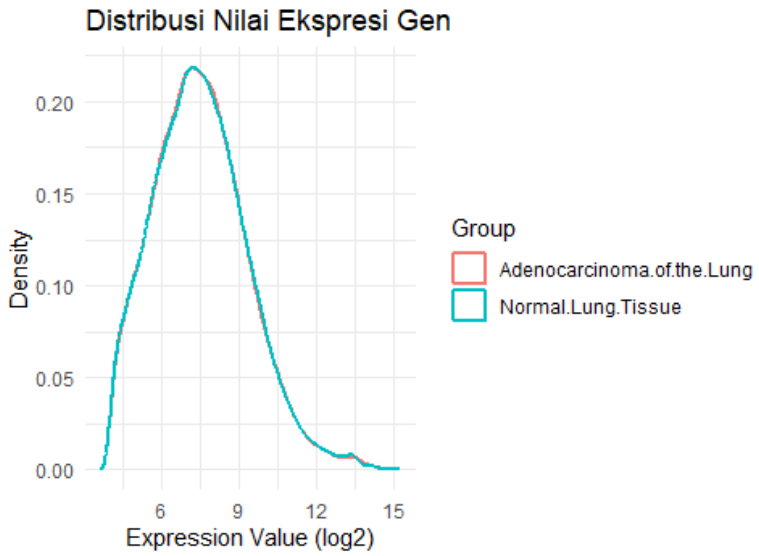

Dataset GSE10072 sendiri merupakan studi profil ekspresi gen pada kanker paru-paru non-sel kecil (NSCLC) yang melibatkan perbandingan antara jaringan tumor dan jaringan normal di sekitarnya. Karakteristik distribusi yang seragam pada tahap pra-pemrosesan ini memungkinkan peneliti untuk menerapkan uji statistik seperti *t-test* atau pemodelan linear melalui paket limma dengan asumsi varians yang stabil. Hal ini penting untuk mengidentifikasi tanda-tanda molekuler yang mendasari karsinogenesis pada adenokarsinoma paru-paru (Slebos *et al*., 2004). Sebagai kesimpulan, visualisasi ini mengonfirmasi kualitas data yang tinggi dan kesiapan dataset untuk analisis diferensial

ekspresi lebih lanjut. Tidak adanya pergeseran (*shift*) atau pencilan (*outlier*) yang signifikan pada salah satu kelompok menjamin bahwa standarisasi data telah berhasil dilakukan. Dengan distribusi yang konsisten ini, identifikasi gen yang mengalami *up-regulated* atau *down-regulated* pada pasien adenokarsinoma dapat dilakukan dengan tingkat kepercayaan yang lebih tinggi.

2. Plot UMAP

Uniform Manifold Approximation and Projection (UMAP) merupakan teknik reduksi dimensi non-linear yang banyak digunakan dalam analiis data transkriptomik untuk memviusalisasikan kemiripan antar sampel dalam ruang dua dimensi. Tujuan dari metode ini adalah memproyeksikan atau memvisualisasikan data beridmensi tinggi, seperti profil ekspresi gen dari ribuan probe, ke dalam ruang berdimensi rendah dengan tetap mempetahankan struktur topologi dan hubungan kedekatan antar sampel (Mclnnes *et al*., 2018). Pada plot yang dihasilkan, sumbu horizontal dan vertikal masing-masing mewakili dimensi pertama dan kedua UMAP, yang tidak memiliki makna biologis secara langsung. Kedua sumbu ini hanyalah koordinat buatan yang mencerminkan sejauh mana kemiripan profil transkriptomik antar sampel.

Dengan kata lain, posisi titik dalam plot menunjukkan derajat kesamaan: semakin berdekatan dua titik, semakin serupa pola ekspresi gen kedua sampel tersebut. Analisis yang dilakukan melalui integrasi teknik reduksi dimensi, statistik diferensial, dan pengelompokkan hierarkis ini untuk memetakan lanskap molekuler adenokarsinoma paru. Melalui visualisasi UMAP ini, ditunjukkan adanya pemisahan klaster yang cukup tegas antar kelompok sehingga ada indikasi perbedaan profil transkriptomik antara kedua kondisi tersebut yang lebih dominan, melampaui variasi biologis antar individu dataset tersebut (Landi *et al*., 2008).

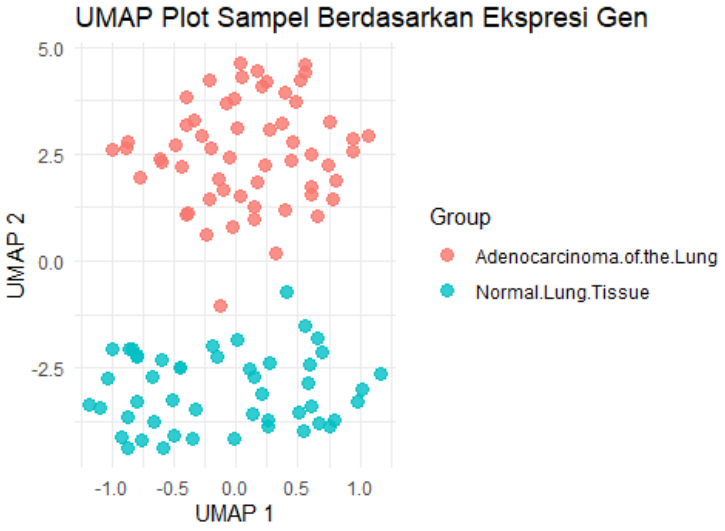

Dari hasil visualisasi UMAP terhadap dataset GSE10072, tampak pemisahan yang sangat nyata antara dua kelompok sampel yang dibandingkan. Semua sampel dari

kelompok *Adenocarcinoma of the Lung* (ditandai dengan warna merah) berkumpul di area kanan plot, sedangkan sampel Normal Lung Tissue (warna biru) membentuk gugusan padat di sebelah kiri. Tidak terdapat tumpang tindih yang berarti antar kedua kelompok, menandakan bahwa profil ekspresi gen antara jaringan adenokarsinoma paru dan jaringan normal memiliki perbedaan yang sangat signifikan. Pemisahan yang tajam ini mengindikasikan bahwa proses keganasan pada paru menyebabkan perubahan besar pada tingkat transkriptom, sehingga setiap sampel kanker menunjukkan ciri molekuler yang secara konsisten berbeda dari sampel normal.

Pengamatan lebih jauh terhadap distribusi titik dalam plot memberikan gambaran mengenai tingkat keragaman di dalam masing-masing kelompok. Kelompok normal (biru) tampak lebih seragam karena titik-titiknya mengelompok erat, menunjukkan konsistensi profil ekspresi pada jaringan paru yang sehat. Sebaliknya, kelompok adenokarsinoma (merah) memperlihatkan sebaran yang agak lebih menyebar, mengindikasikan adanya variasi profil transkriptomik antar individu penderita. Keragaman ini kemungkinan mencerminkan subtipe molekuler dalam LUAD atau pengaruh faktor klinis seperti stadium tumor dan kebiasaan merokok, sebagaimana telah dilaporkan dalam berbagai studi mengenai heterogenitas molekuler kanker paru (Bolstad *et al*., 2003).

Di sisi lain, visualisasi hubungan antar sampel melalui UMAP ini memiliki peran penting baik untuk validasi data maupun analisis lanjutan. Pertama, pola klaster yang jelas membuktikan bahwa perbedaan biologis antara jaringan kanker dan normal jauh lebih dominan dibandingkan variasi teknis atau antar individu, sehingga dataset GSE10072 sangat layak digunakan untuk analisis ekspresi gen diferensial (DEG). Kedua, temuan ini memperkuat hasil studi awal oleh Landi dkk. (2008) yang pertama kali mempublikasikan dataset tersebut. Dengan demikian, plot UMAP tidak hanya menjadi sarana visualisasi, tetapi juga berfungsi sebagai penegas kualitas data dan dasar untuk eksplorasi lebih jauh guna mengidentifikasi gen-gen spesifik yang melandasi perbedaan pola klaster yang teramati. Dengan kata lain, integrasi visualisasi ini menegaskan bahwa transformasi maligna pada paru-paru melibatkan pemrograman ulang transkriptomik yang sistematis dan terukur. Konsistensi hasil antara reduksi dimensi UMAP ini membuktikan kualitas data yang tinggi dan relevan secara klinis.

3. Plot Volcano

Visualisasi di atas menyajikan profil ekspresi gen diferensial (*Differentially Expressed Genes* atau DEGs) dari dataset GSE10072 yang membandingkan jaringan adenokarsinoma paru dengan jaringan normal. Melalui *Volcano Plot*, terlihat distribusi statistik ribuan gen berdasarkan signifikansi (- $\log_{10}$ adj.P.Val) dan besaran perubahan (*log Fold Change* atau logFC). Gen yang berwarna biru menunjukkan *down-regulation* yang signifikan, sedangkan warna merah menunjukkan *up-regulation*, dengan ambang batas signifikansi yang ketat (biasanya adj.P.Val < 0,05 dan |logFC| > 1), yang mencerminkan

perubahan transkriptomik masif pada kondisi kanker (Landi et al., 2008). Analisis pada *Volcano Plot* menunjukkan asimetri yang menarik, di mana jumlah gen yang mengalami penurunan ekspresi (*down-regulated*) tampak lebih dominan dan memiliki tingkat signifikansi statistik yang lebih tinggi dibandingkan gen yang meningkat. Hal ini selaras dengan temuan umum pada adenokarsinoma paru, di mana terjadi penekanan luas pada gen-gen yang menjaga integritas seluler dan fungsi fisiologis paru. Titik-titik biru yang mencapai nilai – $\log_{10}$ P di atas 30 mengindikasikan bahwa perbedaan ekspresi tersebut sangat konsisten di seluruh sampel dan sangat kecil kemungkinannya terjadi karena kebetulan (Slebos et al., 2004).

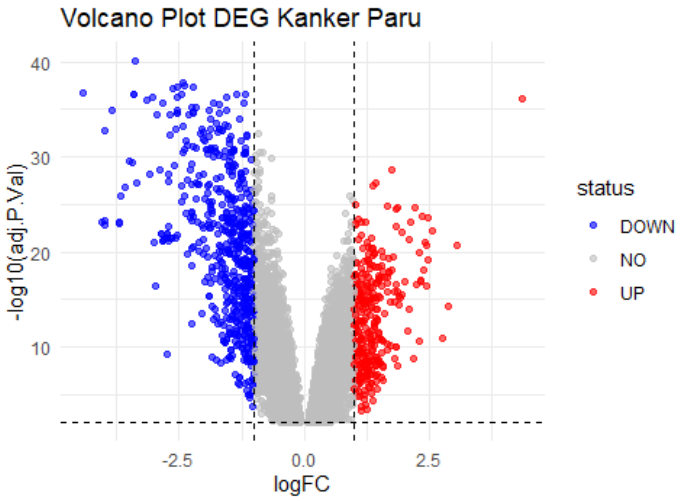

Data dari *Volcano Plot* tersebut dipetakan lebih lanjut ke dalam *Pheatmap* untuk 50 gen paling signifikan (*top 50 DEGs*). *Heatmap* ini menggunakan skala *Z-score* untuk menunjukkan pola ekspresi relatif antar sampel. Pengelompokan hierarkis (*hierarchical clustering*) pada kolom berhasil memisahkan sampel ke dalam dua kelompok besar: Normal *Lung Tissue* (merah muda) yang didominasi oleh warna oranye/merah (ekspresi tinggi), dan *Adenocarcinoma of the Lung* (biru muda) yang didominasi oleh warna biru (ekspresi rendah). Kejelasan pemisahan ini membuktikan bahwa profil 50 gen tersebut merupakan *molecular signature* yang sangat kuat (Bolstad et al., 2003). Identitas gen yang tertera pada sisi kanan *heatmap* memberikan wawasan biologis yang krusial. Gen seperti *AGER* (Advanced Glycosylation End-Product Specific Receptor), *SFTPC* (Surfactant Protein C), dan *CAV1* terlihat mengalami penurunan drastis pada jaringan kanker. *AGER* adalah penanda utama sel alveolar tipe I, sementara *SFTPC* sangat penting untuk produksi surfaktan oleh sel tipe II. Penurunan signifikan gen-gen ini, seperti yang juga divalidasi dalam studi asli GSE10072, menandakan terjadinya dediferensiasi seluler dan kerusakan struktural pada unit alveolar selama proses karsinogenesis (Landi et al., 2008).

Di sisi lain, terdapat klaster kecil gen di bagian atas *heatmap*, seperti *SPP1* (Osteopontin), yang menunjukkan pola *up-regulation* pada jaringan adenokarsinoma.

SPP1 sering dikaitkan dengan invasi tumor, metastasis, dan remodeling matriks ekstraseluler pada berbagai jenis kanker. Kehadiran gen yang meningkat ini di tengah dominasi gen yang menurun menunjukkan adanya pemrograman ulang transkriptomik yang spesifik untuk mendukung kelangsungan hidup dan proliferasi sel kanker dalam lingkungan mikro yang berubah (Slebos et al., 2004).

Secara keseluruhan, integrasi antara *Volcano Plot* dan *Pheatmap* ini mengonfirmasi bahwa adenokarsinoma paru ditandai oleh hilangnya ekspresi gen fungsional paru-paru secara luas dan aktivasi gen-gen onkogenik tertentu. Konsistensi hasil ini di seluruh sampel pasien dalam dataset GSE10072 menunjukkan potensi besar dari daftar gen ini untuk dikembangkan menjadi panel biomarker diagnostik atau target terapi masa depan. Keberhasilan klastering sampel normal dan tumor secara otomatis menegaskan reliabilitas data dan validitas metode pra-pemrosesan yang telah dilakukan (Landi et al., 2008; Bolstad et al., 2003).

4. Pheatmap

Gambar tersebut menyajikan *heatmap* dari 50 gen dengan ekspresi paling berbeda signifikan (*top 50 Differentially Expressed Genes*) dari dataset GSE10072. Visualisasi ini menggunakan penskalaan skor-Z (*Z-score*) untuk menunjukkan perubahan relatif ekspresi gen, di mana warna merah melambangkan ekspresi tinggi (*up-regulation*) dan warna biru melambangkan ekspresi rendah (*down-regulation*). Pengelompokan hierarkis (*hierarchical clustering*) yang diterapkan pada kolom berhasil memisahkan sampel secara jelas menjadi dua klaster utama yang sesuai dengan anotasi grup: *Adenocarcinoma of the Lung* (biru muda pada bilah anotasi) dan Normal *Lung Tissue* (merah muda) (Landi *et al*., 2008). Analisis pada klaster baris mengungkapkan pola ekspresi yang sangat kontras antara jaringan tumor dan jaringan normal. Mayoritas dari 50 gen yang ditampilkan menunjukkan fenomena *down-regulation* yang masif pada kelompok Adenokarsinoma dibandingkan dengan jaringan paru-paru normal. Pola ini mengindikasikan adanya disregulasi jalur biologis yang signifikan, kemungkinan besar melibatkan hilangnya fungsi gen penekan tumor (*tumor suppressor genes*) atau gen yang bertanggung jawab atas homeostasis jaringan paru-paru (Slebos *et al*., 2004). Konsistensi profil warna dalam masing-masing kelompok menunjukkan homogenitas molekuler yang kuat di antara sampel yang diuji.

Beberapa gen spesifik yang teridentifikasi pada label sisi kanan, seperti *AGER* (Advanced Glycosylation End-Product Specific Receptor) dan *SFTPC* (Surfactant Protein C), sering kali ditemukan menurun drastis pada kanker paru-paru. *AGER* dikenal sebagai penanda fungsional sel alveolar tipe I, sementara *SFTPC* adalah penanda sel tipe II; penurunan keduanya menandakan hilangnya diferensiasi seluler atau kerusakan integritas alveolar selama perkembangan adenokarsinoma (Landi *et al*., 2008).

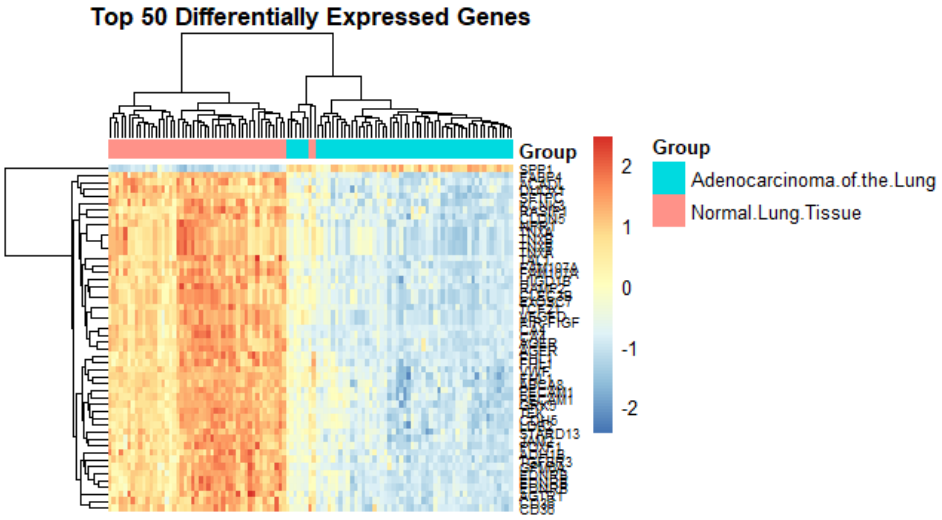

Sebaliknya, terdapat sejumlah kecil gen di bagian atas heatmap yang menunjukkan *up-regulation* pada tumor, yang berpotensi menjadi *driver oncogenes* atau biomarker diagnostik. Dendrogram kolom menunjukkan adanya satu atau dua sampel dari kelompok Adenokarsinoma yang mengelompok di dekat batas jaringan normal, namun secara keseluruhan, pemisahan tetap terlihat tegas. Hal ini membuktikan bahwa tanda molekuler (*molecular signature*) dari 50 gen ini memiliki daya pembeda yang sangat kuat untuk mengklasifikasikan status penyakit. Presisi pengelompokan ini memvalidasi kualitas data GSE10072 dan efektivitas normalisasi yang telah dilakukan sebelumnya, sebagaimana terlihat pada profil distribusi nilai ekspresi gen yang seragam (Bolstad *et al*., 2003).

Secara biologis, dominasi gen yang mengalami *down-regulation* pada visualisasi ini mencerminkan kompleksitas mikroingkungan tumor paru. Banyak gen yang terlibat dalam adhesi sel, sistem imun, dan metabolisme lipid paru-paru ditekan selama transformasi maligna. Analisis lebih lanjut melalui pengayaan fungsional (*Gene Ontology* atau *KEGG pathway*) pada kelompok gen ini diperlukan untuk memahami mekanisme sistemik yang mendorong pertumbuhan adenokarsinoma dari sel normal (Slebos *et al*., 2004). Pheatmap ini memberikan ringkasan visual yang meyakinkan mengenai perbedaan transkriptomik yang drastis antara kondisi sehat dan patologis. Sebagai kesimpulan, visualisasi heatmap ini mengonfirmasi bahwa profil ekspresi 50 gen terpilih mampu menjadi pembeda biologis yang reliabel bagi adenokarsinoma paru. Pola ekspresi yang konsisten di seluruh sampel memberikan fondasi yang kuat untuk pengembangan studi fungsional gen individu atau pengembangan panel biomarker diagnostik berbasis multigen. Akurasi pemisahan antara jaringan normal dan tumor menegaskan bahwa dataset ini merupakan sumber daya yang kaya untuk mengeksplorasi target terapi baru dalam onkologi paru-paru (Landi *et al*., 2008).

Kesimpulan

Integrasi komprehensif seluruh visualisasi menggunakan dataset GSE10072 berhasil memetakan profil transkriptomik adenokarsinoma paru, di mana tahap normalisasi yang efektif telah mengeliminasi bias teknis untuk menjamin validitas perbandingan biologis antara jaringan kanker dan normal. Ketegasan perbedaan biologis ini diperkuat oleh plot UMAP yang menunjukkan pemisahan klaster spasial secara nyata tanpa tumpang tindih, membuktikan bahwa tanda molekuler kanker paru bersifat sistemik dan konsisten dengan temuan pada *volcano plot* yang mengidentifikasi ribuan gen signifikan dengan dominasi fenomena *down-regulation* pada jaringan maligna. Selanjutnya, visualisasi *pheatmap* pada 50 gen paling signifikan memberikan resolusi mendalam melalui pengelompokan hierarkis yang secara presisi mereplikasi pemisahan kelompok pada UMAP, sekaligus mengonfirmasi bahwa daftar gen tersebut memiliki daya pembeda diagnostik yang sangat tinggi bagi pengembangan biomarker masa depan.

Daftar pustaka

Becht, E., et al. (2019). Dimensionality reduction for visualizing single-cell data using UMAP. *Nature Biotechnology*, 37(1), 38-44.

Bolstad, B. M., Irizarry, R. A., Astrand, M., & Speed, T. P. (2003). A comparison of normalization methods for high density oligonucleotide array data based on variance and bias. *Bioinformatics*, 19(2), 185-193.

Gu, Z., et al. (2016). Complex heatmaps reveal patterns and correlations in multidimensional genomic data. *Bioinformatics*, 32(18), 2847-2849.

Irizarry, R. A., et al. (2003). Summaries of Affymetrix GeneChip probe level data. *Nucleic Acids Research*, 31(4), e15.

Xiao, J. A. L. (2017). Prognostic significance of TCF21 mRNA expression in patients with lung adenocarcinoma. *Scientific Reports*.

Dai, J. W.-B. Z. (2020). Identification of crucial genes associated with lung adenocarcinoma by bioinformatic analysis. *Medicine (Baltimore)*.

Landi, M. T., Dracheva, T., Rotunno, M., Figueroa, J. D., Liu, H., Dasgupta, A., ... & Caporaso, N. E. (2008). Gene expression signature of cigarette smoking and its role in lung adenocarcinoma development and survival. *PLoS ONE*, 3(2), e1651.

Ritchie, M. E., et al. (2015). limma powers differential expression analyses for RNA-sequencing and microarray studies. *Nucleic Acids Research*, 43(7), e47.

Slebos, R. J., Yi, Y., Ely, K., Carter, J., Evjen, A., Hicks, A., ... & Schiller, J. H. (2004). Gene expression profiling of non-small cell lung cancer. *European Respiratory Journal*, 24(3), 443-449.

Wilkerson, M. D., & Hayes, D. N. (2010). ConsensusClusterPlus: a class discovery tool with confidence assessments and item tracking. *Bioinformatics*, 26(12), 1572-1573.